使用可能データセット一覧

LLM講座2 2026 最終課題
使用可能データセット一覧

2026-11-02

■ この資料について

開発モデルの学習に使用できるデータセットを列挙したものです。
ここに載っていないデータセットは使用できません。取得は下記の URL からのみ行ってください。

本一覧は「使ってよい」の列挙です。掲載は運営が推奨することを意味しません。
どれを使うか、あるいはどれも使わないかは、みなさんが選んでください。
各項目に書いた性質は選ぶための材料です。

用途の指定はありません。推論用 LLM (Qwen/Qwen3.5-0.8B) の学習、検索用エンコーダの学習、リランカーの学習のいずれに使っても構いません。ルール 6.2 のとおり、学習以外の用途 (データの分析、評価、ハイパーパラメータの調整、チェックポイントの選択) にも使用できます。

■ 使用できるデータセット

1. NIILC 質問応答
    - 取得元 https://github.com/mynlp/niilc-qa
    - ライセンス CC BY-SA 4.0
    - 帰属表示 必要 (下記「ライセンス表記の書き方」参照)
    - 取得量 1.1 MB
    - 件数 dev 800 / test 200
    - 内容 人手で作成されたデータセットです。オープンドメインの短答で、1 問に複数の解答が付くことがあります。解答長の中央値が 4 文字程度で、本一覧の中でもっとも短いものです。
2. cl-nagoya/auto-wiki-qa
    - 取得元 https://huggingface.co/datasets/cl-nagoya/auto-wiki-qa
    - ライセンス CC BY-SA 4.0
    - 帰属表示 必要
    - 取得量 227 MB
    - 件数 2,377,503
    - 内容 機械生成のデータセットです。tokyotech-llm/Swallow-MX-8x7b-NVE-v0.1 が日本語 Wikipedia から問いと解答を生成したもので、人手による検証は経ていません。
      本一覧で唯一の機械生成データセットです (下記「公開済みデータセットの扱いについて」参照)。件数はもっとも多く、Wikipedia のスナップショットは2024-01-01 時点でもっとも新しいものです。
      注意 件数が多いため、全件を扱おうとすると Colab の実行時間を圧迫します。
3. TyDi QA (日本語・Primary Task)

- 取得元 https://huggingface.co/datasets/google-research-datasets/tydiqa
- ライセンス Apache-2.0
- 帰属表示 推奨
- 取得量 2.8 GB
- 件数 11 言語の合計で train 166,916 / dev 18,670 (日本語はこのうち約 1 割)
- 内容 人手で作成されたデータセットです。本文中のスパンをバイト位置で指す形式です。
  Wikipedia のスナップショットは 2019-02-01 時点で、本一覧の中でもっとも古いものです。
  注意 日本語を使う場合は Primary Task に限られます。Gold Passage (secondary) は公式 README が日本語を除外していると明記しています。
  配布ファイルは 11 言語混在のため、日本語の抽出が前処理として必要です。
  取得量 2.8 GB は減らせません。日本語は 12 個のシャード全体にほぼ均等に散らばっており、一部のシャードだけを取得する方法が使えません。
  Colab の実行時間とディスクを見込んでから着手してください。
  公式 GitHub が案内する storage.googleapis.com は匿名アクセスを拒否するため、取得元は上記 Hugging Face のみとします。

4. JaQuAD
   - 取得元 https://github.com/SkelterLabsInc/JaQuAD
     (data/train/jaquad_train_*.json、data/dev/)
   - ライセンス CC BY-SA 3.0 Unported
   - 帰属表示 必要
   - 取得量 25 MB
   - 件数 train 31,748 / dev 3,939
   - 内容 人手で作成されたデータセットです。単一の段落から解答のスパンを抜き出す抽出型で、形式は SQuAD 1.1 です。
     注意 リポジトリ内で 34 ファイルに分割されています。1 ファイルの取得では済みません。
     ライセンスが CC BY-SA 3.0 で、他のデータセットおよび配布チャンク (4.0) と版が違います。
5. JSQuAD (JGLUE)
   - 取得元 https://github.com/yahoojapan/JGLUE
     (datasets/jsquad-v1.3/train-v1.3.json)
   - ライセンス CC BY-SA 4.0
   - 帰属表示 必要
   - 取得量 23 MB
   - 件数 train 62,697 / dev 4,442
   - 内容 人手で作成されたデータセットです。JaQuAD と同じ抽出型です。
     問い文の約 2 割は疑問文ではなく、定義文や名詞句の形をしています。
     解答長の中央値は 5 文字程度です。Wikipedia のスナップショットは2021-11-01 時点です。

6. JEMHopQA
   - 取得元 https://github.com/aiishii/JEMHopQA
   - ライセンス CC BY-SA 4.0
   - 帰属表示 必要

    - 取得量 1 MB 未満
    - 件数 train 1,059 / dev 120
    - 内容 人手で作成されたデータセットです。2 つの事実をたどって答えるマルチホップの問いで、解答は短い語句です。本一覧の中で件数はもっとも少ないものです。
7. cl-nagoya が公開するデータセット群
    - 取得元 https://huggingface.co/cl-nagoya/datasets
    - ライセンス データセットごとに異なります。使用するデータセットのページで確認してください。
    - 帰属表示 使用するデータセットのページの記載に従ってください。
    - 件数 2026-11-01 時点で 21 件
    - 内容 名古屋大学の研究室が公開しているデータセット群です。配布パイプラインが使用している検索用エンコーダ (cl-nagoya/ruri-v3-310m) とリランカー (cl-nagoya/ruri-v3-reranker-310m) の学習に使われたデータが含まれており、検索側の学習に向いています。2026-11-01 時点で検索・ランキング向けのものはruri-v3-dataset-reranker、ruri-v3-dataset-reranker-preview、ruri-v3-dataset-ft、ruri-dataset-reranker、ruri-dataset-ft、ruri-dataset-v2-ft、ruri-dataset-v2-pt、auto-wiki-qa-nemotron です。
      注意 上記 1〜6 と違い、ライセンスが一律ではありません。ライセンスが明示されていないデータセット、およlicense:other と表示されるデータセットが含まれます。
      使用するデータセットのページとデータセットカードを必ず確認してください。
      ruri-dataset-v2-pt はカードに「WIP: 正式公開準備中」と記載されています。
      ruri-v3-dataset-ft のように、複数の出典を混ぜたデータセットでは出典ごとにライセンスが異なります。カードの License Information の記載に従ってください。

■ データの扱い

・取得元の固定
上記の URL から取得したものを使用してください。同名の再配布版や改変版は使用できません。
Hugging Face で同名のデータセットが複数見つかる場合がありますが、上記以外は使用不可です。ライセンス表記が食い違っている例もあります。

・推論時の読み込みは不可
本一覧は学習に使うデータの一覧です。配布した RAG のコードで成果物を生成するときに読み込むこと、推論用のプロンプトに埋め込むこと、配布した Wikipedia データベースに追加することは、いずれもできません。

・機械的な処理は可
重複除去、長さによるフィルタ、形式の統一、サブセットの抽出など、ルールに基づいて機械的に行う処理は認められます。

・人手による加工・選別は不可
データ内容の修正、追記、要約、翻訳、ラベル付け、解答の作成・書き換え、内容を確認したうえでの採否判断は認められません。

・処理の実行場所
データに対するすべての処理を Google Colab 上で実行してください。

TyDi QA と cl-nagoya/auto-wiki-qa は取得量と件数が大きいため、この条件が実行時間に効きます。7 番に含まれるデータセットには、これよりさらに大きいもの(ruri-dataset-v2-pt など) があります。

・自前の合成データ
配布したチャンクから機械的に作成したデータ、および Qwen/Qwen3.5-0.8B とその派生モデルを用いて期間中に生成した合成データは使用できます。
入力に人手で作成した問題や解答を含めてはいけません。

・問題の学習は不可
問題は使用可能なデータに含まれません。問題を閲覧すること、および問題から統計量・特徴量その他の情報を取得して、学習・モデル選択・ハイパーパラメータ調整・データ作成に利用することは禁止です。

■ 配布コーパスとの照合について

上記 1〜6 のデータセットは、いずれも日本語 Wikipedia の全体から作られています。
配布したチャンク集合は日本語 Wikipedia の一部 (49,043 記事) であり、作成時点も範囲も一致しません。7 番に含まれるデータセットのうち日本語 Wikipedia を出典とするものにも、同じことが当てはまります。

そのため、学習データの問いに対する解答が配布コーパスの中に存在しない行が、どのデータセットにも一定の割合で含まれます。これはデータセットの不備ではなく、出どころの違いによるものです。

こうした行をそのまま学習に使うと、「渡された文脈に答えが無くても何か答える」振る舞いをモデルが覚える可能性があります。

これを避ける方法として、解答の文字列を含むチャンクが配布パイプラインの検索上位に来るかどうかで学習データを絞り込む手順を推奨します。機械的な処理として認められる操作です。実行するかどうかはみなさんの裁量です。

■ ライセンス表記の書き方

開発モデルを Hugging Face で公開する際、ベースモデルと使用したデータセットの出典・ライセンスを README に記載してください。

CC BY-SA のデータセット (NIILC / cl-nagoya/auto-wiki-qa / JaQuAD / JSQuAD / JEMHopQA) は記載が必須です。作成者または出典、ライセンス名とリンク、改変の有無を書いてください。

NIILC QA (https://github.com/mynlp/niilc-qa) is licensed under
CC BY-SA 4.0 (https://creativecommons.org/licenses/by-sa/4.0/).
Modified: filtered and reformatted for training.

JaQuAD のみライセンスが CC BY-SA 3.0 Unported です。リンクは
https://creativecommons.org/licenses/by-sa/3.0/ になります。

TyDi QA (Apache-2.0) は、学習に使うだけであれば法的な義務は生じませんが、出典を README に列挙してください。

データセット本体を再配布しない限り、ライセンス全文を同梱する必要はありません。

7 番のデータセット群を使用した場合は、使用した個々のデータセットのリポジトリ ID と、そのページに記載されたライセンスを README に列挙してください。

配布したチャンク集合も日本語 Wikipedia 由来の CC BY-SA 4.0 です。
こちらも併せて README に記載してください。

学習データ

- NIILC QA (CC BY-SA 4.0) https://github.com/mynlp/niilc-qa
- cl-nagoya/auto-wiki-qa (CC BY-SA 4.0)
  https://huggingface.co/datasets/cl-nagoya/auto-wiki-qa
- JSQuAD / JGLUE (CC BY-SA 4.0) https://github.com/yahoojapan/JGLUE
- 配布チャンク集合 (日本語 Wikipedia 由来、CC BY-SA 4.0)

■ 公開済みデータセットの扱いについて

ルールでは、使用を認められたモデル以外によるアノテーションや合成データ作成を禁止しています。一方で本一覧には、他のモデルが生成したデータ、または他のモデルの出力で選別されたデータが含まれます。2 番の cl-nagoya/auto-wiki-qa、および 7 番に含まれる auto-wiki-qa-nemotron やリランカーのスコアで選別されたデータが該当します。

本一覧に掲載されたデータセットは、この禁止事項の例外として使用できます。

禁止されるのは、参加者自身が他のモデルや API を用いてデータを生成・加工する行為です。
本一覧のデータセットを記載どおりに使用する行為は、これに該当しません。

なお cl-nagoya/auto-wiki-qa の生成元モデルは Apache-2.0 であり、出力の利用を制限する条項はありません。

■ 変更履歴

2026-11-02 初版